

概率论与数理统计习题课-3rd

复习复习!

2024 年 12 月 21 日

目录

1 大数定律与中心极限定律	1	2.2 例题示范	7
1.1 基础知识	1		
1.2 例题示范	2	3 参数估计	9
2 样本及抽样分布	3	3.1 基础知识	9
2.1 基础知识	3	3.2 例题示范	11

1 大数定律与中心极限定律

1.1 基础知识

(弱) 大数定律讨论的是, 在何种条件下, 独立同分布随机变量的均值依概率收敛于期望. 称随机变量序列 $\{Y_n\}_{n=1}^{\infty}$ 依概率收敛于 Y , 如果对任意的 $\epsilon > 0$, 都有

$$\lim_{n \rightarrow \infty} \mathbb{P}\{|Y_n - Y| \geq \epsilon\} = 0,$$

或者, 等价地,

$$\lim_{n \rightarrow \infty} \mathbb{P}\{|Y_n - Y| < \epsilon\} = 1.$$

1.1 定理 (伯努利大数定律). 独立同分布的 **0-1** 随机变量服从弱大数定律. 具体地说, 设 p 是每次 *Bernoulli* 试验中事件 A 发生的概率, n_A 为 n 次试验中事件 A 发生的次数, 那么对任意的 $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}\left\{\left|\frac{n_A}{n} - p\right| < \epsilon\right\} = 1.$$

1.2 定理 (辛钦大数定律). 期望存在的独立同分布的随机变量服从弱大数定律. 具体地说, 设独立同分布的随机变量 X_1, X_2, \dots 期望为 $\mathbb{E}(X_k) = \mu$, 那么对任意的 $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P} \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| < \epsilon \right\} = 1.$$

中心极限定理讨论的是, 在何种条件下, 独立随机变量和的极限分布为正态分布. 和大数定律不同的是, 通过中心极限定理我们可以获取关于估计量分布的信息——从而提供了一种计算独立随机变量和的近似概率的简单方法. 它还解释了一个引人注目的事实, 即如此多的自然“种群”的经验频率呈现钟形 (即正态) 曲线.

1.3 定理 (独立同分布的中心极限定理). 设独立同分布的随机变量 X_1, X_2, \dots 期望为 $\mathbb{E}(X_k) = \mu$, 方差为 $D(X_k) = \sigma^2 > 0$, 那么标准化的随机变量之和的极限分布服从标准正态分布: 对任意 t ,

$$\lim_{n \rightarrow \infty} \mathbb{P} \left\{ \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \leq t \right\} = \Phi(t).$$

下面的中心极限定理给出了二项分布的正态近似.

1.4 定理 (棣莫弗-拉普拉斯中心极限定理). 设 p 是每次 *Bernoulli* 试验中事件 A 发生的概率, n_A 为 n 次试验中事件 A 发生的次数, 那么标准化的 n_A 的极限分布服从标准正态分布: 对任意 t ,

$$\lim_{n \rightarrow \infty} \mathbb{P} \left\{ \frac{n_A - np}{\sqrt{np(1-p)}} \leq t \right\} = \Phi(t).$$

1.2 例题示范

1.5 示例. 掷一枚质地均匀的骰子 100 次, 记 X_i 为第 i 次掷出的点数, \bar{X} 为 X_1, \dots, X_{100} 的均值, 试用中心极限定理估计概率 $P\{3 \leq \bar{X} \leq 4\}$.

解. 由题意可得 $\mathbb{E}(X_i) = 3.5$, $D(X_i) = \frac{35}{12}$, $\mathbb{E}(\bar{X}) = 3.5$, $D(\bar{X}) = \frac{7}{240}$, 于是由中心极限定理,

$$\mathbb{P}\{3 \leq \bar{X} \leq 4\} \approx \mathbb{P} \left\{ \frac{3 - 3.5}{\sqrt{7/240}} \leq \frac{\bar{X} - 3.5}{\sqrt{7/240}} \leq \frac{4 - 3.5}{\sqrt{7/240}} \right\} = 2\Phi(2.9277) - 1 = 0.9966.$$

□

1.6 示例. 进行独立重复试验, 每次试验中事件 A 发生的概率为 0.25. 试问能以 95% 的把握保证 1000 次试验中事件 A 发生的频率与概率相差多少? 此时 A 发生的次数在什么范围内?

解. 记 Y_n 为 1000 次试验中事件 A 发生的次数, 则 $Y_n \sim b(1000, 0.25)$, 且 $\mathbb{E}(Y_n) = 250, D(Y_n) = 187.5$. 设事件 A 发生的频率 $Y_n/1000$ 与概率 0.25 的差为 k , 我们有不等式

$$\begin{aligned} 0.95 &\leq \mathbb{P}\left\{\left|\frac{Y_n}{1000} - 0.25\right| \leq k\right\} = \mathbb{P}\left\{\left|\frac{Y_n - 250}{\sqrt{187.5}}\right| \leq \frac{1000k + 0.5}{\sqrt{187.5}}\right\} \\ &\approx 2\Phi\left(\frac{1000k + 0.5}{\sqrt{187.5}}\right) - 1. \end{aligned}$$

即寻求 k , 使得

$$\Phi\left(\frac{1000k + 0.5}{\sqrt{187.5}}\right) \geq 0.975,$$

查表得 $\frac{1000k+0.5}{\sqrt{187.5}} \geq 1.96$, 解得 $k \geq 0.027$. 这表明能以 95% 的把握保证在 1000 次试验中事件 A 发生的频率与概率相差不大于 0.027. 或者说, 有 95% 的把握说, 在 1000 次试验中事件 A 发生的次数在即在 223 次到 277 次间. \square

2 样本及抽样分布

2.1 基础知识

数理统计的核心问题是利用样本推断总体——我们在获取数据后, 需要使用有效的方法去集中和提取数据中的有关信息, 对所研究的问题做出一定的结论, 这在统计上被称为“推断”. 著名统计学家 C.R.Rao 在其著作《统计与真理——怎样运用偶然性》中概括道:

- 在终极的分析中, 一切知识都是历史;
- 在抽象的意义下, 一切科学都是数学;
- 在理性的基础上, 所有的判断都是统计学.

2.1.1 总体与样本

在一个统计问题中, 我们把研究对象的全体称为**总体**, 构成总体的每个成员称为**个体**. 而在实际问题中, 我们关心个体的数量指标值, 于是总体就是一堆数——

有大有小、有的出现机会大, 有的出现机会小. 因此用一个概率分布去描述和归纳总体是恰当的, 从这个意义看, 总体就是一个随机变量 X .

对总体的观察称为**抽样**: 我们从总体 X 中进行 n 次独立地、重复地观察, 得到 n 个结果 X_1, \dots, X_n , 称为来自总体 X 的、容量为 n 的**简单随机样本**, 简称**样本**. 于是 X_1, \dots, X_n **独立**且与总体 X 有**相同分布** F , 记做 X_1, \dots, X_n i.i.d. $\sim F$.

样本具有**二重性**: 一方面, 由于样本是从总体中随机抽取的, 抽取前无法预知它们的数值, 因此样本是随机变量, 用大写字母 X_1, \dots, X_n 表示; 另一方面, 样本在抽取以后经观测就有确定的观测值, 因此样本又是一组数值, 此时用小写字母 x_1, \dots, x_n 表示是恰当的.

2.1.2 统计量

由于样本本身是一些杂乱无章的数字, 我们需要对数字加工处理, 计算出一些有用的量.

2.1 定义 (统计量). 由样本算出来的量称为统计量, 或者说, 统计量是样本的函数. (注意: 统计量中不能含有未知参数.)

下面列出一些常见的统计量.

- 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$;
- 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)$;
- 样本标准差 $S = \sqrt{S^2}$;
- 样本 k 阶 (原点) 矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, k = 1, 2, \dots$;
- 样本 k 阶中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, k = 1, 2, \dots$.

2.2 命题. 设 X_1, \dots, X_n 为来自总体 X 的样本, $\mathbb{E}(X) = \mu, D(X) = \sigma^2$, 那

么

$$\mathbb{E}(\bar{X}) = \mu, D(\bar{X}) = \frac{\sigma^2}{n}, \mathbb{E}(S^2) = \sigma^2.$$

证明. 我们只证明样本方差的期望是 σ^2 . 注意到 X_k 两两独立意味着

$$\mathbb{E}(\bar{X}^2) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i \cdot \bar{X}) = \mathbb{E}(X_k \cdot \bar{X}),$$

其中

$$\mathbb{E}(X_k \cdot \bar{X}) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_k \cdot X_i) = \frac{n-1}{n} \mathbb{E}(X)^2 + \frac{1}{n} \mathbb{E}(X^2).$$

于是

$$\begin{aligned} \mathbb{E}(S^2) &= \frac{1}{n-1} \sum_{i=1}^n \mathbb{E}(X_i - \bar{X})^2 = \frac{n}{n-1} \left[\mathbb{E}(X_k^2) - 2\mathbb{E}(X_k \cdot \bar{X}) + \mathbb{E}(\bar{X}^2) \right] \\ &= \frac{n}{n-1} \left[\mathbb{E}(X^2) - \frac{n-1}{n} \mathbb{E}(X)^2 - \frac{1}{n} \mathbb{E}(X^2) \right] = \mathbb{E}(X^2) - \mathbb{E}(X)^2 \\ &= D(X) = \sigma^2. \end{aligned}$$

□

2.3 注. 在统计学中, 自由度是指当以样本的统计量来估计总体的参数时, 样本中独立或能自由变化的数据的个数——这里的“度”指的是“维度”. 若样本 X_1, X_2, X_3 的均值 \bar{X} 是事先指定的, 那么此时真正取值“自由”的随机变量只有 2 个: 例如, 当 X_1, X_2 已知时, X_3 不得不取 $3\bar{X} - X_1 - X_2$. 而在计算 n 个样本的方差时, 样本均值已经给定, 此时自由度是 $n-1$.

2.1.3 经验分布函数

若我们有总体 X 的 n 个观察值 x_1, \dots, x_n , 我们可以写出分布的经验分布函数

$$F_n(x) = \frac{\#\{x_i : x_i \leq x\}}{n},$$

即样本观察值小于等于 x 的频率. 可以看到这样的函数满足分布函数的非负、单增、右连续三个条件.

Glivenko–Cantelli 定理指出, 样本容量极大时, 样本的经验分布趋近于总体分布 (a.e.), 这被称为推断统计学的基石.

2.1.4 三大抽样分布

作为样本的函数, 统计量也是随机变量, 它的分布称为**抽样分布**. 以**标准正态变量**为基石而构造的三个著名统计量在实际中有广泛的应用, 它们被称作数理统计中的**三大抽样分布**.

2.4 定义 (卡方分布). 设 X_1, \dots, X_n *i.i.d.* $\sim N(0, 1)$, 则称随机变量

$$\chi^2 = \sum_{i=1}^n X_i^2$$

服从自由度为 n 的 χ^2 分布, 记做 $\chi \sim \chi^2(n)$.

由定义, 不难看出卡方分布关于**自由度**具有**可加性**, 即若 χ_1 与 χ_2 相互独立, $\chi_1 \sim \chi^2(n)$, $\chi_2 \sim \chi^2(m)$, 那么

$$\chi_1 + \chi_2 \sim \chi^2(n + m).$$

此外我们还需熟记卡方分布的期望与方差: 若 $\chi \sim \chi^2(n)$, 那么

$$\mathbb{E}(\chi) = n, D(\chi) = 2n.$$

2.5 定义 (t 分布). 设 $X \sim N(0, 1)$, $Y \sim \chi^2(n)$ 且 X 与 Y 相互独立, 则称随机变量

$$t = \frac{X}{\sqrt{Y/n}}$$

服从自由度为 n 的 t 分布, 记做 $t \sim t(n)$.

注意 t 分布的密度函数和标准正态曲线类似, 呈现“中间高, 两边低, 左右对称”, 但是两侧的尾部概率比 $N(0, 1)$ 大. 于是 t 分布的上分位数满足 $t_\alpha(n) + t_{1-\alpha}(n) = 0$ (互为相反数).

2.6 定义 (F 分布). 设 $U \sim \chi^2(m)$, $V \sim \chi^2(n)$ 且 U, V 相互独立, 则称随机变量

$$F = \frac{U/m}{V/n}$$

服从自由度为 m, n 的 F 分布, 记做 $F \sim F(m, n)$.

由定义不难看出 $t^2(n) = F(1, n)$. 此外 $\frac{1}{F} \sim F(n, m)$, 于是 F 分布的上分位数满足 $F_\alpha(m, n) \cdot F_{1-\alpha}(n, m) = 1$ (互为倒数):

$$1 - \alpha = \mathbb{P}(F \leq F_\alpha(m, n)) = \mathbb{P}\left(\frac{1}{F} \geq \frac{1}{F_\alpha(m, n)}\right).$$

在命题2.2的基础上, 若总体 X 服从正态分布, 我们可以构造出一些常用统计量, 在假设检验中有着很广泛的应用.

2.7 定理 (单正态总体的抽样分布). 设样本 X_1, X_2, \dots, X_n *i.i.d.* $\sim N(\mu, \sigma^2)$, \bar{X}, S^2 分别为样本均值与方差, 那么

$$1. \bar{X} \sim N(\mu, \sigma^2/n), \text{ 于是 } U = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1);$$

$$2. \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1); \text{ 最关键的一点! 请务必记住.}$$

3. \bar{X} 与 S^2 独立, 于是

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

我们可以看到, 最终构造的统计量 $\frac{\bar{X} - \mu}{S/\sqrt{n}}$ 不含总体方差这一未知参数, 并且分布信息可以通过查表得到——从而可以在 σ 未知的情况下, 给出 μ 的区间估计.

有的时候, 我们需要比较两个正态总体的参数, 下面的统计量允许我们在参数 μ_1, μ_2 未知的情况下, 对 σ_1/σ_2 做出推断.

2.8 定理 (双正态总体的抽样分布). 设样本 X_1, X_2, \dots, X_m *i.i.d.* $\sim N(\mu_1, \sigma_1^2)$, Y_1, Y_2, \dots, Y_n *i.i.d.* $\sim N(\mu_2, \sigma_2^2)$, 且两样本之间相互独立. $\bar{X}, \bar{Y}, S_1^2, S_2^2$ 分别为两个样本的均值与方差, 那么

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(m-1, n-1).$$

证明. 在上一定理的基础上, 我们有 $\frac{(m-1)S_1^2}{\sigma_1^2} \sim \chi^2(m-1)$, $\frac{(n-1)S_2^2}{\sigma_2^2} \sim \chi^2(n-1)$, 于是由 F 分布的定义可知定理成立. \square

2.2 例题示范

2.9 示例. 设 x_1, \dots, x_{16} 为来自 $N(\mu, \sigma^2)$ 的样本, 经计算 $\bar{x} = 9$, $s^2 = 5.32$, 试求 $\mathbb{P}\{|\bar{x} - \mu| < 0.6\}$.

解. 对于单正态总体, 我们考虑构造服从 t 分布的统计量. 由于 $\bar{x} - \mu \sim$

$N(0, \sigma^2/n)$, $\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$, 那么

$$t := \frac{\frac{\bar{x} - \mu}{\sigma/\sqrt{n}}}{\sqrt{\frac{(n-1)s^2}{\sigma^2}/(n-1)}} = \frac{\sqrt{n}(\bar{x} - \mu)}{s} = \frac{4}{\sqrt{5.32}}(\bar{x} - \mu) \sim t(15).$$

于是

$$\begin{aligned}\mathbb{P}\{|\bar{x} - \mu| < 0.6\} &= \mathbb{P}\{|\bar{x} - \mu| < 0.6\} = \mathbb{P}\left\{|t| < \frac{4 \times 0.6}{\sqrt{5.32}}\right\} \\ &= 0.6854.\end{aligned}$$

□

2.10 示例. 若随机变量 $X \sim F(n, n)$, 证明 $\mathbb{P}\{X < 1\} = 0.5$.

证明. 由 F 分布的定义有 $Y := 1/X \sim F(n, n)$ 与 X 同分布, 于是

$$\mathbb{P}\{X < 1\} = \mathbb{P}\{Y < 1\} = \mathbb{P}\{1/X < 1\} = \mathbb{P}\{X > 1\}.$$

另一方面, 由于 X 是连续型随机变量, 我们有 $\mathbb{P}\{X < 1\} + \mathbb{P}\{X > 1\} = 1$, 于是 $\mathbb{P}\{X < 1\} = 0.5$. □

2.11 示例. 设 x_1, \dots, x_{15} 是总体 $N(0, \sigma^2)$ 的一个样本, 求

$$\frac{x_1^2 + \dots + x_{10}^2}{2(x_{11}^2 + \dots + x_{15}^2)}$$

的分布.

解. 由于 x_1, \dots, x_n i.i.d. $N(0, 1)$, 那么

$$\frac{1}{\sigma^2}(x_1^2 + \dots + x_{10}^2) \sim \chi^2(10), \quad \frac{1}{\sigma^2}(x_{11}^2 + \dots + x_{15}^2) \sim \chi^2(5),$$

于是

$$\frac{x_1^2 + \dots + x_{10}^2}{2(x_{11}^2 + \dots + x_{15}^2)} = \frac{\frac{1}{\sigma^2}(x_1^2 + \dots + x_{10}^2)/10}{\frac{1}{\sigma^2}(2(x_{11}^2 + \dots + x_{15}^2)/5)} \sim F(10, 5).$$

□

3 参数估计

3.1 基础知识

3.1.1 点估计

对于未知参数 θ , 我们选用统计量 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 的取值作为 θ 的一个估计量, $\hat{\theta}(x_1, x_2, \dots, x_n)$ 作为估计值. 常用的点估计有矩估计和最大似然估计.

矩估计

矩估计的基本想法是“替换原理”: 用相应的样本矩 (的函数) 替换总体矩 (的函数), 并且尽量选取低阶矩. 矩估计的理论依据是辛钦大数定律

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{\mathbb{P}} \mathbb{E}(X^k).$$

例如若总体 X 的期望 μ 与方差 σ^2 未知, 我们通常选用一阶样本原点矩 (即样本均值) 和二阶样本中心矩分别作为二者的矩估计:

$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

最大似然估计

最大似然估计法是求点估计用得最多的方法, 它的基本想法是, 未知参数 θ 的估计应该是使得当前结果出现可能性最大的那个 θ .

设 X_1, \dots, X_n 为来自总体 X 的样本, X 的分布已知而参数 θ 未知. 最大似然估计的方法步骤为:

1. 求出当前事件出现的概率/密度, 它是样本和未知参数的函数 $L(X_1, \dots, X_n; \theta)$, 我们称之为似然函数;
2. 寻求使得似然函数达到最大的点 $\hat{\theta}$ 作为 θ 的估计

$$\hat{\theta} = \arg \max_{\theta \in \Theta} L(X_1, \dots, X_n; \theta).$$

其中 Θ 为参数 θ 的取值范围, 例如方差的参数空间是 $\mathbb{R}_{\geq 0}$.

若 X 为离散型随机变量, 它的分布律为 $\mathbb{P}\{X = x\} = p(x; \theta)$, 由样本的独立性,

$$L(x_1, \dots, x_n; \theta) := \mathbb{P}\{X_1 = x_1, \dots, X_n = x_n\} = \prod_{i=1}^n p(x_i; \theta).$$

若 X 为连续型随机变量, 它的密度为 $f(x; \theta)$, 此时似然函数为

$$L(x_1, \dots, x_n; \theta) := \prod_{i=1}^n f(x_i; \theta).$$

3.1 注. 大多情况下, 似然函数 L 关于 θ 可微, 于是极值点可由似然方程

$$\frac{d}{d\theta} L(X_1, \dots, X_n; \theta) = 0$$

解出驻点, 再得到最大值点. 特别当驻点唯一时, 最大值点只能是此驻点. 进一步地, 由于似然函数 L 和它的对数函数 $\ln L$ 同时取得最值, 实际计算中我们也常用对数似然方程

$$\frac{d}{d\theta} \ln L(X_1, \dots, X_n; \theta) = 0$$

解出 (对数可以把乘积转换为求和的形式, 便于求导, 特别对正态分布、指数分布这种密度包含指数函数的情况, 能够极大的方便我们的计算).

若有多个未知参数 $\theta_1, \dots, \theta_m$, 则从似然方程组 $\frac{\partial}{\partial \theta_i} L, i = 1, \dots, m$ 或者对数似然方程组解出驻点, 再判断驻点是否为最大值点.

估计量的评选标准

由于不同方法可能得到不同的点估计, 我们需要对不同的估计量做出评价. 常用的标准有无偏性、有效性及相合性等, 这需要点估计量分别满足如下要求:

- **无偏性:** 称 $\hat{\theta}$ 是 θ 的无偏估计量, 如果 $\mathbb{E}(\hat{\theta}) = \theta$;
- **有效性:** 称无偏估计量 $\hat{\theta}_1$ 比无偏估计量 $\hat{\theta}_2$ 更有效, 如果对任意 $\theta \in \Theta$, 都有 $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$ 且存在某个 θ 使得不等号严格成立;
- **相合性:** 称 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 为参数 θ 的相合估计量, 如果 $\hat{\theta} \xrightarrow{\mathbb{P}} \theta$.

3.2 注. 由辛钦大数定律, 样本的二阶中心矩是方差的相合估计, 但不是无偏估计——由命题2.2, 样本方差才是总体方差的无偏估计, 此外样本方差也是总体方差的相合估计.

3.1.2 区间估计

由于时间缘故, 本节未能来得及准备, 私密马赛.

3.2 例题示范

3.3 示例. 设 x_1, x_2, x_3 是来自总体的样本, 是证明下列统计量都是总体均值 μ 的无偏估计, 并比较方差存在时的有效性.

$$(1) \hat{\mu}_1 = \frac{1}{2}x_1 + \frac{1}{3}x_2 + \frac{1}{6}x_3;$$

$$(2) \hat{\mu}_2 = \frac{1}{3}x_1 + \frac{1}{3}x_2 + \frac{1}{3}x_3;$$

$$(3) \hat{\mu}_3 = \frac{1}{6}x_1 + \frac{1}{6}x_2 + \frac{2}{3}x_3.$$

解.

$$\mathbb{E}(\hat{\mu}_1) = \frac{1}{2}\mathbb{E}(x_1) + \frac{1}{3}\mathbb{E}(x_2) + \frac{1}{6}\mathbb{E}(x_3) = \frac{1}{2}\mu + \frac{1}{3}\mu + \frac{1}{6}\mu = \mu,$$

$$\mathbb{E}(\hat{\mu}_2) = \frac{1}{3}\mathbb{E}(x_1) + \frac{1}{3}\mathbb{E}(x_2) + \frac{1}{3}\mathbb{E}(x_3) = \frac{1}{3}\mu + \frac{1}{3}\mu + \frac{1}{3}\mu = \mu,$$

$$\mathbb{E}(\hat{\mu}_3) = \frac{1}{6}\mathbb{E}(x_1) + \frac{1}{6}\mathbb{E}(x_2) + \frac{2}{3}\mathbb{E}(x_3) = \frac{1}{6}\mu + \frac{1}{6}\mu + \frac{2}{3}\mu = \mu.$$

于是它们都是 μ 的无偏估计. 不妨设总体方差为 σ^2 , 那么

$$D(\hat{\mu}_1) = \frac{1}{4}D(x_1) + \frac{1}{9}D(x_2) + \frac{1}{36}D(x_3) = \frac{1}{4}\sigma^2 + \frac{1}{9}\sigma^2 + \frac{1}{36}\sigma^2 = \frac{7}{18}\sigma^2,$$

$$D(\hat{\mu}_2) = \frac{1}{9}D(x_1) + \frac{1}{9}D(x_2) + \frac{1}{9}D(x_3) = \frac{1}{9}\sigma^2 + \frac{1}{9}\sigma^2 + \frac{1}{9}\sigma^2 = \frac{1}{3}\sigma^2,$$

$$D(\hat{\mu}_3) = \frac{1}{36}D(x_1) + \frac{1}{36}D(x_2) + \frac{4}{9}D(x_3) = \frac{1}{36}\sigma^2 + \frac{1}{36}\sigma^2 + \frac{4}{9}\sigma^2 = \frac{1}{2}\sigma^2.$$

不难看出 $D(\hat{\mu}_2) < D(\hat{\mu}_1) < D(\hat{\mu}_3)$, 于是 $\hat{\mu}_2$ 最有效. □

3.4 示例. 设总体密度函数如下, x_1, \dots, x_n 为来自总体的样本, 试求未知参数的矩估计:

$$(1) p(x; \theta) = (\theta + 1)x^\theta, \quad 0 < x < 1, \quad \theta > 0;$$

$$(2) p(x; \theta, \mu) = \frac{1}{\theta}e^{-\frac{x-\mu}{\theta}}, \quad x > \mu, \quad \theta > 0.$$

解. (1) 由 $\mathbb{E}(X) = \int_0^1 x \cdot p(x; \theta) dx = \frac{\theta+1}{\theta+2}$, 于是 $\theta = \frac{1-2\mathbb{E}(X)}{\mathbb{E}(X)-1}$, 从而由替换原理, 矩估计 $\hat{\theta} = \frac{1-2\bar{x}}{\bar{x}-1}$;

(2) 总体的期望和方差分别为

$$\begin{aligned}\mathbb{E}(X) &= \int_{\mu}^{\infty} x \cdot p(x; \theta) dx = \int_0^{\infty} \frac{t}{\theta} e^{-\frac{t+\mu}{\theta}} dt = \theta + \mu, \\ \mathbb{E}(X^2) &= \int_{\mu}^{\infty} x^2 \cdot p(x; \theta) dx = \int_0^{\infty} \frac{(t+\mu)^2}{\theta} e^{-\frac{t}{\theta}} dt = 2\theta^2 + 2\mu\theta + \mu^2, \\ D(X) &= \mathbb{E}(X^2) - \mathbb{E}(X)^2 = \theta^2.\end{aligned}$$

于是 $\theta = \sqrt{D(X)}$, $\mu = \mathbb{E}(X) - \sqrt{D(X)}$, 从而由替换原理, 矩估计 $\hat{\theta} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$, $\hat{\mu} = \bar{x} - \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$.

□

3.5 示例 (均匀分布的矩估计). 设样本 X_1, \dots, X_n 来自均匀分布 $U(a, b)$, 给出未知参数 a, b 的矩估计.

解. 由于 $\mathbb{E}(X) = \frac{a+b}{2}$, $D(X) = \frac{(b-a)^2}{12}$, 不难得出

$$a = \mathbb{E}(X) - \sqrt{3D(X)}, \quad b = \mathbb{E}(X) + \sqrt{3D(X)}.$$

我们用一阶样本原点矩和二阶样本中心矩分别替换 $\mathbb{E}(X)$ 和 $D(X)$ 即可:

$$\hat{a} = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}, \quad \hat{b} = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

□

3.6 示例 (均匀分布的最大似然估计). 参照教材例 6.

3.7 示例. 设总体概率密度如下, x_1, \dots, x_n 为来自总体的样本, 试求未知参数的最大似然估计:

$$(1) \quad p(x; \theta) = \sqrt{\theta} x^{\sqrt{\theta}-1}, \quad 0 < x < 1, \quad \theta > 0;$$

$$(2) \quad p(x; \theta, c) = \frac{1}{\theta} e^{-\frac{x-c}{\theta}}, \quad x > c, \quad \theta > 0.$$

解. (1) 似然函数为 $L(\theta) = \theta^{\frac{n}{2}} (x_1 x_2 \cdots x_n)^{\sqrt{\theta}-1}$, 于是对数似然函数为

$$\ln L(\theta) = \frac{n}{2} \ln \theta + (\sqrt{\theta} - 1) \sum_{i=1}^n \ln x_i.$$

于是似然方程为

$$\frac{d}{d\theta} \ln L(\theta) = \frac{n}{2\theta} + \frac{\sum_{i=1}^n \ln x_i}{2\sqrt{\theta}} = 0,$$

解之得唯一驻点 $\hat{\theta} = \left(\frac{1}{n} \sum_{i=1}^n \ln x_i \right)$.

(2) 记 $x_{(1)} = \min\{x_1, \dots, x_n\}$, 此时似然函数为

$$L(\theta) = \theta^{-n} \exp \left\{ -\frac{1}{\theta} \sum_{i=1}^n (x_i - c) \right\}, \quad c < x_{(1)},$$

注意到对数似然函数

$$\ln L(\theta) = -n \ln \theta - \frac{1}{\theta} \sum_{i=1}^n (x_i - c), \quad c < x_{(1)}$$

关于 c 单调增, 要使似然函数达到最大, c 应在限制范围 $c < x_{(1)}$ 内尽可能取大, 于是最大似然估计 $\hat{c} = x_{(1)}$. 另一方面, 我们令 $\ln L(\theta, \hat{c})$ 关于 θ 的导数为 0 解出似然方程得

$$\hat{\theta} = \frac{\sum_{i=1}^n (x_i - \hat{c})}{n} = \bar{x} - x_{(1)}.$$

□